

Agent IA de triage médical

Centre Hospitalier Saint-Aurélien — Proof of Concept
Rapport technique et recommandations stratégiques
Benoit Girard · IA Engineer · juin 2026

Sommaire

Sommaire	1
Contexte et objectifs	3
Périmètre et taxonomie	3
Données	3
Ce que contiennent réellement les corpus imposés	3
Conception retenue	4
Dataset produit	4
Conformité RGPD	5
Séparation des jeux	6
Entraînement	6
Le format de dialogue	6
Fine-tuning supervisé avec LoRA, sous Unsloth	7
Réglage des hyperparamètres	7
Alignement par préférences	8
Évaluation	9
Protocole	9
Résultats	10

Ce qui est appris et ce qui se transfère	12
Performance selon la nature du cas	12
Contrôles de sécurité	12
Robustesse aux entrées dégradées	13
Apport mesurable de l'alignement	14
Analyse d'erreurs	14
 Infrastructure et performance	 15
Architecture de service	15
Livrer un adaptateur ou un modèle fusionné ?	15
Latence et débit	16
Empreinte d'entraînement	16
 Industrialisation	 16
Intégration et déploiement continus	16
Traçabilité	17
Sécurité de l'endpoint	17
Surveillance après déploiement	17
 Limites et risques	 17
 Passage en production : checklist go / no-go	 18
 Feuille de route	 19
 Conclusion	 19
 Annexe A — Reproduire le projet	 19
 Annexe B — Sources, licences et références	 20
 Annexe C — Version évaluée	 20

Contexte et objectifs

Le service des urgences du Centre Hospitalier Saint-Aurélien connaît une surcharge constante. Aux heures de pointe, l'accueil manque d'effectifs, les temps d'attente s'allongent, et le risque est double : faire attendre un patient dont l'état se dégrade, et mobiliser une place de déchocage pour un motif qui n'en relevait pas.

Ce projet livre le **prototype d'un agent d'aide au triage**. À partir d'une description de patient — motif, symptômes, antécédents, constantes relevées à l'accueil — il propose un **niveau de priorité**, le **justifie** et formule une **conduite à tenir**, en traçant chaque interaction pour les audits médicaux.

L'agent ne décide pas. Il propose, explique, et rend visible son désaccord éventuel avec la règle de triage explicite du service. La décision reste celle de l'infirmière d'accueil.

L'essai randomisé de Goh *et al.* (*JAMA Network Open*, 2024, référence en annexe B) rapporte qu'un modèle performant mis entre les mains de médecins n'a pas amélioré significativement leur raisonnement, alors que le modèle **seul** obtenait de meilleurs scores que les deux groupes de praticiens. La difficulté est moins la performance brute que l'usage qu'en fait le soignant : d'où une réponse toujours justifiée, l'avis de la règle affiché **à côté** de celui du modèle, et le désaccord exposé plutôt que masqué.

Périmètre et taxonomie

Trois niveaux, repris du cahier des charges — « urgence maximale / modérée / différée » — et rattachés à l'échelle FRENCH utilisée dans les services d'urgence français :

Niveau	Délai de prise en charge	Échelle FRENCH
URGENCE_VITALE	immédiate	tris 1 et 2
URGENCE_MODEREE	quelques heures	tris 3 et 4
CONSULTATION_DIFFEREE	consultation programmée	tri 5

La stratégie du CHSA se déroule en trois phases. Ce rapport couvre les deux premières : validation conceptuelle sur un modèle compact, puis spécialisation par fine-tuning supervisé et alignement par préférences. La troisième — passage à des modèles de plus grande envergure — fait l'objet de la feuille de route en fin de document.

Données

Ce que contiennent réellement les corpus imposés

Le cahier des charges désigne quatre corpus : MediQAI, FrenchMedMCQA, MedQuAD et UltraMedical-Preference. Ce qu'ils permettent réellement de construire :

- **aucun de ces corpus n'est annoté en niveaux de triage**. Ce sont des jeux de questions-réponses médicales et de questions d'examen ;
- **MediQAI est le seul des quatre à décrire des patients**. Sa colonne `clinical_case` porte 3 075 vignettes françaises distinctes — motif, antécédents, et pour 569 d'entre elles les constantes relevées à l'entrée. C'est la seule source authentique francophone du corpus ;
- **FrenchMedMCQA compte 1 080 questions** sur ses trois découpages, dont six décrivent un patient et aucune n'est étiquetable. C'est un jeu de questions de pharmacie ;
- **MedQuAD interroge des pathologies, pas des patients**. Ses fiches de symptômes sont retournées en plaintes de patient, ce qui en tire quelques cas ;
- **UltraMedical-Preference étiquette 38,6 % de ses paires par la seule longueur de la réponse**, mesuré sur 5 000 lignes.

Un cinquième corpus, MedMCQA, a été ajouté hors cahier des charges : les trois corpus exploitables qu'il désigne sont soit francophones, soit sans patient, et la moitié anglophone du corpus authentique serait restée vide sans lui.

Les quatre corpus dont on tire des cas sont lus **intégralement** — 203 384 entrées. UltraMedical-Preference, le cinquième, est réservé à l'évaluation. Le tableau ci-dessous dit où les entrées se perdent.

Corpus	Entrées lues	Pas un patient	Hors bornes	Sans signe	Doublons	Extraits	Livrés
MediQAI	3 075	1 407	514	792	0	362	313
MedQuAD	16 407	15 909	0	315	0	183	120
MedMCQA	182 822	171 251	372	9 038	71	2 090	1 283
FrenchMedMCQA	1 080	1 074	0	6	0	0	0

Deux de ces colonnes recouvrent des décisions de forme, révisables : le motif qui reconnaît une présentation de patient, et les bornes de longueur, fixées de sorte qu'aucun cas retenu ne dépasse le budget de description du service (324 jetons). La troisième est une décision de sécurité : un cas n'est conservé que si la règle y identifie explicitement un signe. Elle écarte à elle seule 10 151 descriptions de patients authentiques, et rend la classe « consultation différée » inatteignable depuis les corpus.

Conception retenue

Le dataset livré repose sur trois apports, dans cet ordre d'importance.


Un catalogue de présentations cliniques. 70 présentations types rencontrées à l'accueil des urgences, rédigées une par une : motif, signes associés, antécédents plausibles, profil de constantes, et **niveau de triage de référence**. Adulte, enfant, femme enceinte, traumatologie, psychiatrie, et les motifs de médecine générale qui encombrer les urgences.

Un générateur de vignettes. Il habille une présentation d'un patient : âge, sexe, antécédents tirés du catalogue, délai d'installation, relevé de constantes cohérent avec la gravité, et formulation variable. L'étiquette vient de la présentation d'origine, **jamais d'une relecture du texte produit** : aucune règle lexicale n'a servi à étiqueter, le modèle ne peut donc pas se contenter d'en réapprendre une.

Des cas extraits des corpus publics. Les vignettes de MediQAI, de MedMCQA et les descriptions de symptômes de MedQuAD sont conservées après retrait de la question d'examen, puis étiquetées par la règle explicite avec une **confiance** moyenne qui les distingue des précédentes. La règle de sécurité décrite plus haut s'applique ici : l'absence de signe ne prouve pas l'absence de gravité — « suspected pneumoperitoneum » ne contient aucun mot d'alerte et reste une urgence chirurgicale. La matière non urgente n'est donc pas étiquetable en sécurité : sur les soixante cas cliniques, la règle reste muette dans 34 cas dont 14 sont urgents, soit une précision de 0,59 si l'on traitait son silence comme une étiquette. Les cas non urgents viennent du catalogue, relus un par un.

Dataset produit

Jeu	Volume	Contenu
Entraînement supervisé	4 000	paires invite / réponse de triage
Validation	500	suivi de la convergence
Test interne	500	même distribution que l'entraînement
Préférences (DPO)	2 400	triplets invite / préférée / rejetée
Évaluation clinique	60	cas écrits à la main, jamais vus



Composition du dataset : équilibre des niveaux, et origine des exemples.

Le corpus est **équilibré** : 1 666 à 1 668 exemples par niveau, 2 500 en français et 2 500 en anglais. 49 % des exemples portent un relevé de constantes ; les autres n'en ont pas, parce qu'à l'accueil le relevé n'est pas toujours disponible au moment du tri.

Origine des exemples. 3 284 des 5 000 paires (66 %) sont des vignettes générées à partir des 70 présentations du catalogue ; 1 716 (34 %) sont extraites des corpus publics — MediQAI 313, MedQuAD 120, MedMCQA 1 283, FrenchMedMCQA 0.

Diversité des réponses attendues. Les 3 284 vignettes ne portent que 70 réponses attendues distinctes — une par présentation d'origine — soit environ 47 répétitions chacune. Sur l'ensemble du jeu, on compte 305 réponses distinctes.

Part du niveau lisible sur les métadonnées. Un vote majoritaire sur les deux seules métadonnées du générateur — délai d'installation et profil de constantes — retrouve le niveau dans 89,6 % des vignettes, et 63,4 % d'entre elles tombent dans une combinaison qui ne va qu'avec un seul niveau.

Chaque exemple porte en outre les champs demandés par le cahier des charges : symptômes, antécédents, constantes, source, **confiance de l'étiquette** — haute pour le catalogue, moyenne pour la règle appliquée à un corpus — et présentation d'origine. La liste exacte des colonnes des trois fichiers est dans la carte de données publiée avec eux, sous la garde d'un test du dépôt.

Conformité RGPD

Le principe premier est la **minimisation par conception** : aucune donnée patient réelle n'entre dans le projet. Les vignettes sont synthétiques ; les corpus publics sont des jeux de recherche sans donnée identifiante.

L'anonymisation Presidio est néanmoins appliquée aux textes issus des corpus, et surtout au **journal d'audit du service** — le seul endroit du système où des données patient réelles se déposeraient durablement une fois l'agent branché au système d'information hospitalier.

Le réglage par défaut de Presidio s'est révélé inutilisable sur du texte médical. Sur 400 exemples du corpus, chacun analysé dans sa langue, les entités DATE_TIME, LOCATION et NRP masqueraient au moins un fragment de récit dans **81 % des cas** :

- DATE_TIME emporte les **délais d'évolution** — « depuis trois semaines », « cette nuit », « depuis deux heures » — et l'**âge** du patient ;
- LOCATION emporte TA, l'abréviation de la tension artérielle, à elle seule cent trente-six fois sur l'échantillon.

Délai, âge et constantes sont précisément les trois critères sur lesquels se décide un niveau de triage. Trois décisions en découlent :

1. **seules les entités réellement identifiantes sont masquées** — nom, téléphone, adresse électronique, identifiants bancaires, adresse IP, numéro de sécurité sociale, date de naissance, URL. Quatre reconnaisseurs absents de Presidio ont été ajoutés et enregistrés dans les deux langues : le numéro de sécurité sociale, le téléphone au format national comme international, et la date de naissance en JJ/MM/AAAA comme en AAAA-MM-JJ ;
2. **le vocabulaire clinique du projet est protégé** : aucun terme du catalogue ni du lexique de triage ne peut être masqué. Cette protection porte sur les entités retenues, qui déraillent elles aussi sur du texte médical : sans elle, « inhibiteurs de recapture de la sérotonine » devient « inhibiteurs de recapture de la <PERSON> » ;

3. **le contrôle qualité est indépendant du détecteur.** Un jeu d'expressions régulières distinct, et non Presidio lui-même, cherche ce qui aurait pu passer : il relève 3 occurrences du motif « civilité suivie d'un nom ».

Séparation des jeux

Le cahier des charges interdit de mélanger entraînement et évaluation. Cette séparation est **vérifiée par le code** : le script de préparation échoue si un tour utilisateur apparaît dans deux découpages, ou si un cas d'évaluation clinique se retrouve à l'entraînement. Mesure sur le dataset livré : `testntrain = 0`, `testnvalidation = 0`, `trainnvalidation = 0`.

La déduplication porte sur le tour utilisateur complet et s'applique **après** toutes les transformations de texte. Une version antérieure dédupliquait avant l'anonymisation : le masquage rendait ensuite identiques des énoncés jusque-là distincts, et ces doublons se répartissaient des deux côtés du découpage.

Entraînement

Le format de dialogue

Le modèle de base ne sait pas dialoguer : il complète du texte. Le fine-tuning lui apprend en même temps un format de dialogue et une tâche. Trois pièges de format ont été rencontrés.

Premier piège : le jeu de données exposait une colonne messages. La bibliothèque d'entraînement détecte cette colonne et re-séréalise les exemples avec le gabarit de dialogue natif du modèle — celui de Qwen3, qui insère un bloc `<think></think>` devant la réponse de l'assistant. Le modèle a donc appris un format que l'inférence ne reproduisait jamais. Rien ne le signalait : les courbes d'entraînement étaient normales.

Deuxième piège : le jeton de fin de séquence était le mauvais. Le tokenizer de Qwen3-1.7B-Base sort d'usine avec `<|endoftext|>`, alors que le format appris se termine par `<|im_end|>`. Le modèle ne disposait d'aucun jeton déclaré pour signaler qu'il avait fini de répondre.

Les deux corrections tiennent en deux gestes : le projet **installe son propre gabarit ChatML** sur le tokenizer et le sauvegarde avec le modèle, et **déclare `<|im_end|>` comme fin de séquence**. Le jeu de données expose prompt et completion plutôt que messages, ce qui a l'avantage supplémentaire de ne calculer la perte que sur la réponse. Entraînement, alignement, évaluation et service partent du même texte, au caractère près.

Le modèle ne s'arrêtait toujours pas.

Troisième piège : un jeton que le modèle ne pouvait pas produire

Le réglage des hyperparamètres a rendu un résultat impossible : **0,000 d'arrêts nets sur les quatre configurations**, à l'unité près, pendant que l'exactitude de triage tournait autour de 0,85. Un modèle sous-entraîné produit un taux faible, pas un zéro exact répété quatre fois.

Les fichiers de résultats livrés ont été régénérés après correction : les arrêts nets des quatre configurations vont de 0,983 à 1,000. La pièce qui établit le diagnostic est la comparaison des modules adaptés, plus bas, où la configuration d'origine — les projections seules — est rejouée à côté de la corrigée.

Ni la mesure — sur un modèle jouet, l'arrêt sur le jeton de fin figure bien dans la sortie — ni le budget de génération — 98 jetons en médiane pour un plafond de 220 — n'expliquent ce zéro. Restaient les poids du modèle de base :

- les vingt-cinq jetons ChatML (151644 à 151668) sont des vecteurs **identiques au bit près**, de norme 0,375 contre 1,62 pour la médiane du vocabulaire : des emplacements réservés, jamais entraînés ;
- `<|im_start|>` et `<|im_end|>` ont une **similarité cosinus de 1,000** ;
- le modèle **lie sa tête de sortie à ses embeddings** (`tie_word_embeddings`), que l'adaptation de rang faible gèle.

Le modèle ne pouvait donc pas émettre `<|im_end|>` de préférence à vingt-quatre autres jetons : ils partagent une seule ligne de sortie, figée sur sa valeur d'initialisation. Déclarer le jeton de fin disait au moteur quel jeton guetter, sans rendre le modèle capable de le produire. C'est un piège propre aux modèles **Base** : la variante Instruct a ces jetons entraînés, et c'est elle qu'utilisent la plupart des recettes LoRA publiées.

La correction : adapter la tête de sortie avec les projections. Trois configurations, protocole identique — 75 pas, 60 cas de validation :

Configuration	Paramètres entraînés	Exactitude	Arrêts nets	Jetons générés
projections seules	17 432 576	0,850	0,000	220
projections + embeddings	328 597 504	0,850	0,000	220
projections + tête de sortie	328 597 504	0,900	1,000	97

Entraîner les seuls embeddings ne sert à rien : la bibliothèque d'adaptation en recopie le module, ce qui **rompt le lien** avec la tête de sortie — laquelle reste gelée.

Le gain dépasse la conformité : en s'arrêtant, le modèle génère 97 jetons au lieu de 220 — **2,3 fois moins de texte à produire** à chaque triage, donc autant de latence de service en moins — et la consigne système cesse de déborder dans la réponse rendue au soignant. La fusion exige en contrepartie de **découpler** la tête de sortie au préalable.

Fine-tuning supervisé avec LoRA, sous Unsloth

L'adaptation par matrices de rang faible n'entraîne que 346 030 080 paramètres sur 2 377 769 984, soit 14,55 % du modèle, ce qui fait tenir l'entraînement sur une carte de 16 Go.

L'entraînement passe par **Unsloth**, qui remplace les noyaux de calcul de transformers par des versions écrites pour ce cas d'usage. L'écart a été mesuré sur la même recette — même rang, mêmes modules adaptés, même lot effectif — montée une fois sur Unsloth et une fois sur transformers + PEFT + TRL.

Moteur	Mémoire GPU maximale	Secondes par pas
transformers + PEFT + TRL	10,03 Go	5,12 s
Unsloth	7,23 Go	6,65 s

Soit 28 % de mémoire en moins, 1,30 fois plus lent, sur 30 pas et à configuration identique.

Sur une carte de 16 Go partagée avec le système, la mémoire économisée prime sur le temps perdu.

Unsloth traite par ailleurs la tête de sortie comme il faut : lui passer `lm_head` parmi les modules adaptés le fait basculer en entraînement pleine matrice et gérer le déliage des poids. Son correctif dédié aux jetons jamais entraînés, `fix_untrained_tokens`, ne détecte en revanche que les lignes d'embedding exactement nulles ; sur ce modèle, dont les jetons ChatML sont des vecteurs dupliqués de norme 0,375, il reste sans effet. Le diagnostic décrit plus haut ne pouvait donc pas être automatisé.

Réglage	Valeur
Modèle de base	Qwen/Qwen3-1.7B-Base
Moteur d'entraînement	Unsloth (noyaux LoRA) sur TRL
Rang LoRA · alpha · dropout	32 · 64 · 0,05
Modules adaptés	projections d'attention et de perceptron, et tête de sortie
Taux d'apprentissage	0,0002
Époques · lot effectif	2 · 16
Longueur de séquence	768 jetons
Précision · gradient checkpointing	bfloat16 · activé (variante Unsloth)
Graine	42

Perte d'entraînement finale 0,0826, perte de validation 0,0030. Cet écart quasi nul ne prouve pas l'absence de sur-apprentissage : le jeu de validation est fait de paraphrases des mêmes présentations que l'entraînement, et une perte aussi basse mesure surtout la restitution du gabarit de sortie. C'est le jeu clinique qui répond à la question ; la courbe de convergence est en annexe du dossier de livrables.

Réglage des hyperparamètres

Quatre configurations ont été comparées dans des conditions identiques — même sous-ensemble, même graine, même nombre de pas — puis jugées sur deux critères : la perte de validation, et l'**exactitude de triage** mesurée par génération. Les deux ne vont pas toujours ensemble, et c'est la seconde qui compte pour le service.

Variante	Paramètres entraînaibles	Perte de validation	Exactitude [IC 95 %]	Mémoire GPU
r32_lr2e-4	346 030 080	0,0782	0,833 [0,72 – 0,91]	13,1 Go
r16_lr2e-4	328 597 504	0,1491	0,800 [0,68 – 0,88]	12,4 Go
r8_lr2e-4	319 881 216	0,2536	0,783 [0,66 – 0,87]	7,1 Go
r16_lr1e-4	328 597 504	0,4553	0,733 [0,61 – 0,83]	13,6 Go

Les quatre variantes ne sont pas séparées par cette mesure. Soixante cas de validation donnent des intervalles qui se recouvrent tous : trois points d'écart, ce sont deux cas. Rejouer la comparaison le confirme — l'ordre des deuxième et troisième places change d'une exécution à l'autre, les noyaux GPU n'étant pas déterministes au bit près.

Ce que la comparaison établit, c'est qu'**aucune des quatre configurations ne dégrade le résultat**, et qu'elles tiennent toutes sur la carte de 16 Go. La configuration retenue est **r32_lr2e-4**, la mieux placée sur cette exécution ; trancher pour de bon demanderait un jeu de validation plus large.

La colonne mémoire ne compare pas les variantes : elles s'exécutent dans le **même processus**, et le pic relevé hérite de ce que l'allocateur CUDA a déjà réservé — deux variantes de rang identique diffèrent ici de plus d'un gigaoctet, davantage que l'écart entre deux rangs successifs. Ces pics bornent le besoin réel, ils ne l'attribuent pas au rang.

Le script de fine-tuning lit cette décision dans le fichier de comparaison, non dans une constante recopiée. Le graphique correspondant est en annexe du dossier de livrables.

Suivi des exécutions : MLflow, auto-hébergé

Le cahier des charges laisse le choix entre MLflow et Weights & Biases. MLflow est retenu parce qu'il s'auto-héberge : un service de suivi reçoit les noms d'expériences, les hyperparamètres, les métriques et parfois des extraits de données, et l'héberger dans l'établissement évite de désigner un sous-traitant au sens de l'article 28 du RGPD. Chaque exécution est en outre résumée dans un fichier JSON versionné sous reports/training/, lisible sans serveur.

Alignement par préférences

Le fine-tuning apprend à répondre ; l'alignement apprend à **préférer**. Entre deux réponses au même cas, on veut celle qui ne sous-évalue pas l'urgence, ne retarde pas la prise en charge, n'affirme pas de diagnostic et respecte la langue imposée.

Origine des paires, et écart au cahier des charges. Le cahier des charges prévoit un entraînement DPO fondé sur les paires d'UltraMedical-Preference. Ce corpus n'est pas utilisé ici pour l'entraînement : ses réponses sont de longues dissertations en anglais, quand le contrat de sortie du triage tient en trois lignes en français, et 38,6 % de ses paires sont étiquetées par la seule longueur de la réponse. L'entraîner dessus apprendrait au modèle à violer le format qu'il vient d'acquérir. Les 2 400 paires livrées sont donc construites à partir du **seul jeu d'entraînement supervisé** : à chaque invite, la réponse de référence est opposée à une variante dégradée selon l'une des quatre stratégies du tableau ci-dessous. UltraMedical-Preference est réservé à l'évaluation, où il sert de mesure d'alignement indépendante de nos données et de nos étiquettes.

Le modèle apprend la différence qu'il trouve entre les deux réponses. Une première version opposait une bonne réponse de trois lignes à une réponse évasive d'une demi-ligne ; la seule différence systématique étant la longueur, le modèle a appris « plus long vaut mieux ». Trois règles encadrent donc le jeu livré :


1. **même format, même longueur.** Chaque défaut est décliné en plusieurs longueurs et l'on retient celle qui colle au plus près de la réponse préférée. Mesure sur le jeu livré : la réponse préférée est la plus longue dans 44 % des paires — aucun signal de longueur exploitable ;

2. **jamais de surclassement en réponse rejetée.** La consigne système impose de surclasser au moindre doute ; opposer une réponse trop prudente comme mauvais exemple apprendrait exactement l'inverse ;
3. **les cas graves pèsent plus,** le sous-triage d'une urgence vitale étant la faute la plus coûteuse.

Défaut introduit dans la réponse rejetée	Paires
Conduite à tenir qui retarde la prise en charge	676
Diagnostic présenté comme certain	627
Réponse hors de la langue imposée	598
Niveau sous-évalué	499

Deux choix protègent l'acquis du fine-tuning. La **référence est le modèle supervisé fusionné**, non le modèle de base : l'alignement ne peut donc pas s'éloigner du format tout juste appris. Et une **perte supervisée sur la réponse préférée** s'ajoute à la perte de préférence, qui seule n'optimise qu'un rapport de vraisemblances — elle peut faire baisser la probabilité des deux réponses pourvu que leur écart se creuse.

Réglage	Valeur
Référence	modèle supervisé fusionné
Beta	0,1
Poids de la perte supervisée	1,0
Taux d'apprentissage	0,000005
Époques · lot effectif	1 · 16



Sur le jeu de validation de préférences tenu à l'écart, le modèle aligné ordonne correctement **100 %** des paires ; les courbes d'entraînement seules ne distingueraient pas un alignement qui généralise d'un alignement qui apprend par cœur.

Évaluation

Protocole

Les chiffres publiés portent sur le **jeu clinique indépendant** : 60 cas écrits à la main, jamais vus à l'entraînement, dont les étiquettes proviennent d'un raisonnement clinique et non de la règle à laquelle le modèle est comparé. 47 % d'entre eux sont des **présentations atypiques** : urgence qui se donne l'air bénin, symptôme spectaculaire mais sans gravité, signe grave explicitement nié, constantes qui contredisent le récit.

Quatre références encadrent les résultats :

- **classe majoritaire** — que donnerait un système répondant toujours la même chose ;
- **prudence maximale** — toujours l'urgence vitale. Ce système ne sous-trie jamais, et envoie tout le monde au déchocage. Il rappelle qu'on ne juge pas la sécurité sans regarder le coût de la prudence ;

- **règle explicite** — lexique bilingue de signes de gravité, gestion des formes fléchies et des négations, lecture des constantes dans le texte. C'est le système qu'un service peut déployer en un après-midi ;
- **classifieur classique** — n-grammes pondérés et séparateur linéaire, entraîné sur les mêmes paires que le modèle. Sa configuration est choisie sur le jeu de validation, sans que le jeu clinique soit consulté. C'est la référence qui dit ce que le fine-tuning apporte par-dessus un apprentissage ordinaire sur les mêmes données.

Aucune estimation n'est publiée nue. L'usage courant « moyenne $\pm$ erreur type » ne convient pas ici : presque tout ce qui est mesuré est une proportion sur quelques dizaines de cas, où l'approximation normale sort de l'intervalle [0, 1] — deux sous-triages sur quarante cas urgents lui donnent une borne basse négative — et annonce une certitude absolue dès qu'une proportion vaut 0 ou 1, c'est-à-dire là où il ne faut surtout pas. Les règles tenues sont donc :

Grandeur	Intervalle publié
Proportions, plus de trente cas	Wilson à 95 %
Proportions, six à trente cas	Clopper-Pearson exact, à couverture garantie
Sous-triage , quel que soit l'effectif	Clopper-Pearson exact — une couverture qui se dégrade n'est pas acceptable sur la métrique de sécurité
Moins de six cas, hors sous-triage	aucun : la fraction brute, et la mention « effectif insuffisant »
Écart entre deux systèmes sur les mêmes cas	McNemar exact, sur les seuls cas discordants
Écart entre deux jeux indépendants	intervalle de Newcombe sur la différence
Comptages exhaustifs du corpus	aucun : ils sont dénombrés, pas estimés
Marge moyenne sur les préférences	aucun : la dispersion par paire n'est pas conservée ; la colonne se lit avec la part de paires bien ordonnées, qui porte l'intervalle
Latences	centiles par rang le plus proche, jamais une moyenne : la distribution est à queue lourde, et le chiffre publié est une latence réellement mesurée

Deux conséquences. Sur 60 cas, un écart de trois points n'est pas un écart. Et **le recouvrement de deux intervalles ne prouve rien** : seul le non-recouvrement établit une différence. Les comparaisons se lisent donc sur un test apparié ou sur l'intervalle de l'écart, jamais sur deux moustaches côte à côte. Dernière réserve : ce rapport publie plusieurs dizaines d'intervalles à 95 %, et un ou deux manqueront leur cible par le seul jeu du hasard. Aucune correction de multiplicité n'est appliquée, ces intervalles décrivant des mesures et non une famille d'hypothèses.


Résultats

Les deux taux de faute ne se rapportent pas à la même population, et c'est délibéré. Le **sous-triage** se compte parmi les seuls cas réellement urgents — vitaux ou modérés : rapporté à l'ensemble, il serait mécaniquement dilué par les consultations différées, où il ne peut pas se produire. Le **surclassement** se compte sur l'ensemble des cas, parce qu'il mesure une charge de service : ce qui intéresse un chef de service, c'est la proportion de patients présentés qui arriveront un cran trop haut.

Le respect du format se lit avec les deux : une réponse illisible sur un cas non urgent n'entre dans aucun des deux taux de faute, et un système muet afficherait 0 % de surclassement, le meilleur score possible de la colonne.

Système	Exactitude [IC 95 %]	Sous-triage, cas urgents [IC 95 %]	Respect du format [IC 95 %]	Surclassement, tous cas [IC 95 %]
Classe majoritaire	0,333 [0,23 – 0,46]	50 % [34 % – 66 %]	100 % [94 % – 100 %]	33,3 % [22,7 % – 45,9 %]
Prudence maximale	0,333 [0,23 – 0,46]	0 % [0 % – 9 %]	100 % [94 % – 100 %]	66,7 % [54,1 % – 77,3 %]
Règle explicite	0,617 [0,49 – 0,73]	55 % [38 % – 71 %]	100 % [94 % – 100 %]	1,7 % [0,3 % – 8,9 %]
Classifieur classique	0,617 [0,49 – 0,73]	27,5 % [15 % – 44 %]	100 % [94 % – 100 %]	20 % [11,8 % – 31,8 %]

Système	Exactitude [IC 95 %]	Sous-triage, cas urgents [IC 95 %]	Respect du format [IC 95 %]	Surclassement, tous cas [IC 95 %]
Qwen3-1.7B-Base	0,083 [0,04 – 0,18]	70 % [53 % – 83 %]	36,7 % [25,6 % – 49,3 %]	26,7 % [17,1 % – 39 %]
SFT + LoRA	0,683 [0,56 – 0,79]	30 % [17 % – 47 %]	100 % [94 % – 100 %]	11,7 % [5,8 % – 22,2 %]
SFT + LoRA + DPO (adaptateur)	0,700 [0,57 – 0,80]	27,5 % [15 % – 44 %]	100 % [94 % – 100 %]	11,7 % [5,8 % – 22,2 %]
SFT + LoRA + DPO (fusionné)	0,700 [0,57 – 0,80]	27,5 % [15 % – 44 %]	100 % [94 % – 100 %]	11,7 % [5,8 % – 22,2 %]




Exactitude et sous-triage sur le jeu clinique indépendant.

La classe majoritaire atteint 0,33 et la prudence maximale 0,33 — cette dernière ne sous-trie jamais, au prix de 66,7 % de surclassement, c'est-à-dire d'un service saturé. La règle explicite atteint 0,62 avec 55 % de sous-triage.

Le modèle fine-tuné et aligné atteint 0,70 [0,57 – 0,80] avec 27,5 % de sous-triage et 100 % de réponses exploitables par le système d'information. **Sur le sous-triage, la mesure qui décide**, le modèle laisse passer 11 cas urgents sur 40 là où la règle en laisse passer 22. Les deux systèmes voient les mêmes cas : 15 urgences que seul le modèle attrape contre 4 que seule la règle attrape, soit un écart établi (McNemar exact, $p = 0,019$). Sur l'exactitude globale, le modèle dépasse la règle de 8 points, mais cet écart-là n'est pas établi sur un jeu de cette taille (14 cas contre 9, $p = 0,405$).

Le classifieur classique — configuration mots_bigrammes, mêmes 4 000 paires d'entraînement — atteint 0,62 avec 27,5 % de sous-triage et 20 % de surclassement, contre 11,7 % pour le modèle. Sur les mêmes cas, le modèle en corrige 9 que le classifieur manque et en manque 4 qu'il corrige (McNemar exact, $p = 0,267$). Sur le sous-triage, les deux systèmes sont à égalité — 11 urgences manquées sur 40 de part et d'autre, 3 cas rattrapés contre 3 perdus ($p = 1,000$). Ce classifieur ne produit que le niveau : la justification et la recommandation, deux des trois champs du contrat de sortie, restent hors de sa portée.

Le modèle de base, non spécialisé, ne rend une décision exploitable que dans 36,7 % des cas, pour 0,08 d'exactitude : c'est la mesure de ce qu'apporte la spécialisation.




Matrices de confusion. La colonne « hors format » isole les réponses inexploitables : les ranger dans une classe de triage fausserait la lecture.

Ce qui est appris et ce qui se transfère

Le modèle a aussi été évalué sur le **jeu de test interne** : même assemblage que l'entraînement, des cas mis de côté avant d'entraîner. Le découpage tire des **lignes**, pas des présentations : les 66 présentations distinctes qu'il contient ont **toutes** été vues à l'entraînement, sous une autre formulation. Ce jeu mesure donc la **restitution** de paraphrases de cas connus — un plafond, pas un transfert — et ses observations, n'étant pas indépendantes, rendent son intervalle optimiste.

L'ampleur de cette restitution se mesure sans le modèle : une sonde linéaire sur n-grammes atteint 0,988 sur les vignettes en découpage aléatoire et 0,773 en découpage par présentation d'origine. Les 22 points qui séparent ces deux chiffres sont la part de reconnaissance de cas déjà vus que contient tout résultat calculé sur ce jeu.


La règle explicite n'est pas reprise ici : ayant servi à filtrer le corpus, elle y retrouve l'étiquette par construction, et la comparer mesurerait ce filtre. Elle garde tout son sens sur le jeu clinique, écrit à la main sans jamais passer par elle. Le classifieur classique, lui, est évalué sur les deux jeux : il apprend des mêmes paires que le modèle et n'a pas vu les cas qu'il juge.



Restitution, transfert, et l'écart entre les deux avec son intervalle.

Le modèle atteint 1,00 [0,97 – 1,00] sur le jeu de test interne et 0,70 [0,57 – 0,80] sur le jeu clinique indépendant, soit 30 points d'écart. L'écart est important : une part de la performance interne tient à la régularité des gabarits de génération, que les cas rédigés à la main ne présentent pas. C'est l'argument le plus fort en faveur d'un corpus d'entraînement issu du terrain.

Performance selon la nature du cas



Exactitude par type de présentation.

Sur les présentations directes, le modèle atteint 0,91 [0,76 – 0,97]. Sur les 28 présentations atypiques prises ensemble, il retombe à 0,46 [0,28 – 0,66]. Sa pire catégorie est « faux rassurant », 0,30 [0,07 – 0,65] sur 10 cas — un effectif qui situe une faiblesse sans la quantifier. C'est le résultat attendu, et c'est celui qui compte : les présentations atypiques sont précisément celles où un tri automatique peut nuire.

Contrôles de sécurité

Le niveau de triage ne dit pas tout : une réponse peut annoncer « urgence vitale » et recommander de revenir demain, ou altérer une constante qu'on lui a donnée. **Six contrôles** sont appliqués à chaque réponse produite, et le tableau ci-dessous en ajoute la synthèse — la part de réponses qui n'en déclenchent aucun.

Contrôle	Modèle final [IC 95 %]
Réponses sans aucun défaut	96,7 % [88,6 % – 99,1 %]
Recommandation incohérente avec le niveau	1,7 % [0,3 % – 8,9 %]
Diagnostic affirmé (interdit par la consigne)	0 % [0 % – 6 %]
Réponse hors de la langue imposée	0 % [0 % – 6 %]
Constante citée mais absente du cas	1,7 % [0,3 % – 8,9 %]
Structure de réponse incomplète	0 % [0 % – 6 %]
Niveau annoncé hors de la taxonomie	0 % [0 % – 6 %]

Ces contrôles sont des règles lisibles, pas un second modèle. C'est un choix : en contexte médical, un contrôle de sécurité doit pouvoir être relu, discuté et corrigé par une équipe soignante.

Un contrôle de sécurité doit lui-même être contrôlé. Les 70 réponses de référence du catalogue sont conformes par construction : les passer au contrôle doit donc ne rien signaler. Ce test a d'abord échoué sur dix d'entre elles, toutes des urgences vitales, pour une raison invisible à la lecture du code : la lecture d'une réponse retire les accents afin de tolérer les fautes d'orthographe du modèle, tandis que les motifs de sécurité étaient écrits avec leurs accents. Ils ne pouvaient jamais correspondre, et le rapport aurait publié un taux d'incohérence entièrement fabriqué — **contre** le modèle.

Ce test de non-régression fait désormais partie de la suite automatisée.

Robustesse aux entrées dégradées

Un service d'accueil ne reçoit pas que des cas bien formés. Dix entrées dégradées sont soumises au modèle : saisie de trois lettres, ponctuation seule, copier-coller de deux pages, question hors domaine, demande de prescription, consigne détournée en français puis en anglais, description en langue tierce et saisie contenant des données identifiantes. Ce qui est vérifié, c'est que l'agent **tient son contrat**, jusqu'au renvoi de données identifiantes : un numéro de téléphone n'a rien à faire dans une justification de triage. Une seule de ces entrées appelle en plus un niveau précis, et le contrôle l'exige : la description en langue tierce décrit une douleur thoracique de vingt minutes avec sueurs, et un triage différé y serait dangereux, si bien formé soit-il.

Contrôle	Modèle final [IC 95 %]
Entrées dégradées traitées sans écart au contrat	90 % [55,5 % – 99,8 %]
Réponse au format attendu	90 % [55,5 % – 99,8 %]
Consigne système non divulguée	100 % [69,2 % – 100 %]
Réponse dans la langue imposée	100 % [69,2 % – 100 %]
Génération arrêtée par le modèle lui-même	100 % [69,2 % – 100 %]
Données identifiantes non renvoyées dans la réponse	100 % [69,2 % – 100 %]
Niveau jamais en contradiction avec l'entrée	100 % [69,2 % – 100 %]

L'entrée « copier-coller de deux pages » produit 825 jetons pour une fenêtre de 768 : la génération s'interrompait sur une erreur, et le contrat d'API acceptait alors quatre mille caractères. Les descriptions sont désormais bornées et **la coupe est annoncée** dans la réponse comme au journal.

1 des 10 entrées dégradées produit une réponse qui s'écarte du contrat de sortie : consigne détournée. Le filet de troncature du service garantit que la consigne système n'atteint jamais le personnel soignant, mais ces cas doivent être repris avant tout usage réel.

Apport mesurable de l'alignement

Sur trois classes, deux modèles proches produisent souvent les mêmes décisions : l'écart entre le modèle supervisé et le modèle aligné se noie dans l'incertitude du jeu clinique. On mesure donc l'alignement là où il s'exprime — **sur des préférences**.

Pour chaque paire de réponses annotée par des humains, on compare la vraisemblance que le modèle attribue à la réponse préférée et à la réponse rejetée, normalisée par la longueur. Le jeu utilisé est **UltraMedical-Preference**, corpus de préférences médicales du cahier des charges, tenu hors de l'entraînement pour les raisons exposées plus haut : la mesure ne dépend ni de nos données ni de nos étiquettes. Les paires annotées sur la seule longueur de la réponse sont écartées : elles mesureraient la verbosité.

Modèle	Paires bien ordonnées [IC 95 %]	Marge moyenne
Qwen3-1.7B-Base	34,7 % [27,5 % – 42,6 %]	-0,0797
SFT + LoRA	36 % [28,8 % – 43,9 %]	-0,1063
SFT + LoRA + DPO (adaptateur)	36 % [28,8 % – 43,9 %]	-0,1066
SFT + LoRA + DPO (fusionné)	35,3 % [28,1 % – 43,3 %]	-0,1074

Sur les 150 paires du jeu externe, le modèle supervisé en ordonne correctement 36 %, le modèle aligné 36 %. **Ces valeurs sont sous le hasard**, qui vaut 50 % sur des paires à deux réponses. Le modèle de base, que notre entraînement n'a pas touché, est au même niveau (34,7 %) : le phénomène précède le fine-tuning et ne le décrit pas. L'explication la plus simple est que l'instrument ne s'applique pas à ce modèle : on compare des vraisemblances par jeton attribuées à de longues dissertations anglaises par un modèle spécialisé sur des réponses françaises courtes et structurées, dont 15 % dépassent en outre sa fenêtre et sont écrêtées. Une évaluation externe de l'alignement reste à construire — sur des préférences de même format que la tâche, c'est la leçon à retenir. Les deux modèles s'accordent sur 150 paires, l'alignement en gagne 0 et en perd 0 : le test de McNemar ne conclut pas ($p = 1,000$).

Analyse d'erreurs


Sur 60 cas, 18 restent mal classés, dont 11 par sous-évaluation — les seules qui présentent un risque pour le patient. Trois cas en détail, sous-triages d'abord :

Cas	Attendu	Prédit	Nature	Description
ev04	urgence vitale	urgence moderee	directe	Patiente de 31 ans, enceinte de 34 semaines, se plaint depuis ce matin de céphalées qui ne cèdent pas, de points lumineux devant les yeux et d'une bar...
ev09	urgence vitale	urgence moderee	directe	A 58-year-old man had a sudden tearing pain in the abdomen radiating to his back while gardening. He nearly fainted. He is known to have an aortic ane...

Cas	Attendu	Prédit	Nature	Description
ev11	urgence vitale	urgence moderee	faux rassurant	Femme de 71 ans, diabétique de longue date, se dit seulement « très fatiguée » depuis deux heures, avec une vague nausée et un essoufflement inhabitue...

Infrastructure et performance

Architecture de service



La séparation est délibérée. La passerelle est légère — ni torch, ni poids de modèle — et se redéploie en quelques secondes sans toucher au modèle ; le serveur d'inférence se met à jour sans toucher à la logique métier. Le contrat OpenAPI rend l'intégration au système d'information indépendante des deux.

Trois points d'entrée : la sonde de santé, le **questionnaire adaptatif** — les questions posées dépendent du motif, et la collecte s'arrête dès qu'un signe de détresse vitale apparaît — et le **triage**, qui renvoie le niveau, sa justification, la conduite à tenir, et le **niveau qu'aurait retenu la règle explicite**. Quand les deux divergent, l'interface d'accueil le signale.

Le questionnaire compile ses réponses en **phrases**, et non en questions suivies de leur réponse. La description produite est relue par la règle explicite, et « Y a-t-il une difficulté à respirer ? non » y est lu comme une difficulté à respirer : un rhume dont le patient a tout nié ressortait classé urgence vitale, avec ce signe en justification. Écrire « Pas de difficulté à respirer » — une négation que la règle sait traiter — règle le problème, et donne au modèle un texte qui ressemble à ce qu'un soignant écrirait.

Livrer un adaptateur ou un modèle fusionné ?

Un fine-tuning LoRA produit deux objets livrables : l'**adaptateur** seul, qui s'applique à chaud sur un modèle de base, et le **modèle fusionné**, où l'adaptation est intégrée aux poids. Les deux portent le même apprentissage à l'arrondi près. Les deux ont été évalués côte à côte, sur le même jeu clinique.

	Adaptateur	Modèle fusionné
Exactitude sur le jeu clinique	0,700 [0,57 – 0,80]	0,700 [0,57 – 0,80]
Latence médiane	796 ms	433 ms
Poids à télécharger	67 Mo	3,78 Go
Modèle de base requis	qwen3-1.7b-triage-sft-merged	aucun
Servable à chaud par vLLM	oui, sur le modèle supervisé fusionné	oui, seul

Accord entre les deux jeux de prédictions : **100 %**. Les écarts résiduels sont du bruit numérique attendu — la fusion additionne un delta en simple précision avant de repasser en bfloat16, et l'ordre d'accumulation diffère. Un écart de plusieurs points aurait signalé une fusion défectueuse, pas du bruit.

Les deux livraisons sont **indiscernables en précision** : l'écart observé vaut moins d'un cas sur 60. Le choix se joue donc entièrement sur des critères d'exploitation.

Servir l'adaptateur à chaud suppose que le serveur héberge le modèle supervisé fusionné — c'est au-dessus de lui que l'alignement a été entraîné — puis lui applique l'adaptateur : vLLM le fait, mais cela fait deux artefacts à apparier, une révision de plus à épingler, et une occasion de plus de servir le mauvais modèle de base. L'adaptateur reste utile à l'évaluation et à l'itération, où il évite de réexporter plusieurs gigaoctets ; **c'est le**

modèle fusionné qui est livré et servi. L'adaptateur supervisé, lui, n'est pas servable à chaud du tout — il entraîne la tête de sortie en entier, que le serveur refuse —, ce qui est le prix de la correction du jeton de fin et une raison de plus de livrer un modèle fusionné.

Latence et débit

Les mesures portent sur POST /triage, c'est-à-dire sur ce que l'infirmière d'accueil appelle : la passerelle interroge le moteur, puis applique la règle explicite, anonymise la description et la réponse, et écrit au journal d'audit avant de répondre. Ce travail-là compte dans le temps d'attente, et le critère de passage en production porte sur le total, pas sur la seule génération.

Requêtes simultanées	Latence médiane	95 ^e centile	Débit
1	1474 ms	1683 ms	0,67 req/s
4	1542 ms	1830 ms	2,42 req/s
8	1592 ms	2245 ms	4,71 req/s

À une requête à la fois, la latence médiane est de 1474 ms et le 95^e centile de 1683 ms. C'est l'ordre de grandeur d'une interaction à l'accueil : le temps de saisie du motif suivant. Sur ce total, 28 ms reviennent à la passerelle elle-même, et le reste à la génération. Sous charge, le débit passe à 4,7 requêtes par seconde, soit 7,0 fois celui d'une requête à la fois, et le 95^e centile à 2245 ms, soit 1,3 fois celui mesuré sans concurrence. Le regroupement des requêtes par vLLM absorbe donc la concurrence sans effondrer la latence perçue. Les mesures portent sur vLLM 0.11.0, et non sur la version 0.29.0 épinglée dans la pile : celle-ci exige l'adressage virtuel unifié de CUDA, que le poste de mesure n'expose pas. Une mesure sur l'hôte de déploiement reste à faire.

Le graphique correspondant est en annexe du dossier de livrables.

Empreinte d'entraînement

Phase	Durée	Mémoire GPU maximale
Réglage des hyperparamètres	31 min	13,6 Go
Fine-tuning supervisé	57 min	7,4 Go
Alignement par préférences	48 min	9,8 Go

Une carte grand public de 16 Go suffit à spécialiser un modèle de 1,7 milliard de paramètres. C'est le principal enseignement d'infrastructure de cette phase, et il conditionne le chiffre du passage à l'échelle.

Industrialisation

Intégration et déploiement continus

Le pipeline distingue deux objets qui évoluent à des rythmes différents. La **passerelle** est reconstruite à chaque poussée sur la branche principale. Le **modèle** reçoit une version figée lorsque le dépôt est étiqueté `modele-v*` : le dataset et les cartes sont republiés, puis une étiquette de même nom est posée sur les dépôts du Hub.

Cette étiquette est le pivot du mécanisme. Le job de déploiement relance l'hébergeur — Modal — en lui passant cette révision, et le serveur d'inférence recharge les poids à **cette révision précise** depuis le Hub, là où un pointeur sur la branche par défaut changerait de contenu à chaque publication. Aucune image n'a donc à embarquer trois gigaoctets de poids, et une nouvelle version du modèle se livre sans reconstruire la passerelle, ni l'inverse. Hors étiquette de modèle, la révision transmise reste celle en place : redéployer la passerelle ne change pas le modèle servi.

Le déploiement reste **désarmé par défaut** : sans la variable `DEPLOY_ENABLED`, la chaîne construit, éprouve et publie, mais ne touche à rien de vivant. C'est l'état livré — un dépôt cloné ne peut pas déployer chez quelqu'un par accident.

L'intégration continue exécute le style, l'analyse statique de sécurité, l'audit des vulnérabilités connues des dépendances, les tests avec seuil de couverture, puis **construit l'image de service et vérifie qu'elle démarre**

et répond — y compris qu'un appel sans clé est bien refusé.

Traçabilité

Chaque triage est consigné : identifiant d'interaction, horodatage, description **anonymisée**, niveau proposé, niveau de la règle et signes qui l'ont motivée, réponse rendue **anonymisée**, latence, modèle réellement chargé, moteur, durée de conservation.

Le texte est anonymisé par le module d'audit lui-même, sans faire confiance à son appelant. Le masquage porte sur **les deux textes**, et pas seulement sur la description reçue : la justification produite par le modèle reprend le récit du soignant, et ramènerait au journal un nom qu'on venait d'en écarter. Il enchaîne par ailleurs **les deux langues** : l'API accepte du texte libre, le modèle est bilingue, et le moteur français ne repère pas un nom dans une syntaxe anglaise — le journal est le seul endroit du système où une donnée personnelle se dépose, et pour un an. Enfin, la version de modèle inscrite est **celle réellement chargée** au démarrage, pas une constante de configuration.

Sécurité de l'endpoint

Mesure	Mise en œuvre
Authentification	clé d'API obligatoire ; le service refuse de démarrer sans elle
Comparaison des clés	à temps constant, pour ne pas laisser fuiter la clé par la durée de réponse
Limitation de débit	quota par appelant sur fenêtre glissante. L'identité de comptage est l'en-tête seulement s'il a été vérifié, l'adresse de l'appelant sinon
Moteur d'inférence	protégé par sa propre clé (vllm serve --api-key) dès qu'il est joignable hors de la boucle locale : lui seul n'a ni quota, ni audit, ni anonymisation
Sonde de santé	ni clé ni quota, donc aucun détail : elle signale la panne, jamais l'adresse du moteur
Secrets	jamais dans le dépôt ; variables d'environnement chiffrées côté hébergeur
Conteneur	utilisateur sans privilège, image de base épinglée par empreinte, dépendances épinglées
Journal d'audit	monté sur un volume persistant, sinon la traçabilité disparaît au redéploiement

Surveillance après déploiement

Indicateur	Seuil d'alerte	Réaction
Sonde /health	deux échecs consécutifs	redémarrage du conteneur, alerte
Latence 95 ^e centile	dépassement du double de la référence	vérification de la charge GPU
Taux de réponses hors format	supérieur à 2 % sur une heure	gel de la version, retour à la précédente
Désaccord modèle / règle	supérieur à 25 % sur une journée	revue clinique de l'échantillon
Taux d'erreur HTTP	supérieur à 1 %	alerte d'exploitation

Le désaccord modèle / règle est l'indicateur le plus utile : sans étiquette, calculable en continu, il détecte une dérive avant qu'un patient n'en pâtisse.

Limites et risques

Le catalogue clinique n'a pas été validé par un urgentiste. Il a été rédigé par un ingénieur à partir de la littérature de triage. C'est la limite principale du projet, et le premier point de la feuille de route. Tant qu'elle n'est pas levée, l'agent ne peut pas sortir du cadre d'un prototype.

La majorité des exemples d'entraînement est synthétique. Les vignettes générées sont variées, équilibrées et cliniquement cohérentes, mais elles ne portent pas le désordre du langage réel : récits rapportés par un tiers, informations contradictoires, barrière de la langue, patients qui minimisent. Les cas extraits des corpus, eux, sont authentiques, mais leur étiquette vient de la règle. Le jeu d'évaluation écrit à la main atténue ce biais sans le supprimer.

Le jeu d'évaluation est petit. 60 cas donnent des intervalles de confiance larges. Les comparaisons présentées ne permettent de trancher que des écarts francs, et c'est pour cela qu'ils sont publiés avec leurs intervalles. L'avantage du modèle sur le classifieur classique n'est ainsi établi sur aucune des deux mesures : ce que le fine-tuning apporte par-dessus un apprentissage ordinaire reste à démontrer sur un jeu plus grand, et ce rapport ne le démontre pas.

Aucune vérité terrain externe n'entre dans les chiffres publiés. Les étiquettes viennent du catalogue, de la règle explicite, ou des cas rédigés à la main — toutes de la même source. Le catalogue et le jeu d'évaluation ont de plus le même auteur, ce qui laisse subsister une proximité de style entre ce sur quoi le modèle apprend et ce sur quoi il est jugé. Le seul jeu réellement externe, UltraMedical-Preference, mesure l'alignement et non le triage, et son verdict est inexploitable pour ce modèle. Une évaluation sur des cas rédigés par un tiers, ou tirés de dossiers réels, reste à construire.

Les réponses attendues sont peu diverses. La mémorisation est donc possible, et c'est la raison pour laquelle les chiffres publiés sont calculés sur le jeu clinique et non sur le jeu de test interne.

Une partie du niveau est lisible sur la forme des vignettes générées. Le délai d'installation et le profil de constantes y sont liés au niveau plus nettement que dans la réalité. Le lien est en partie clinique — une plainte ancienne avec des constantes normales est effectivement moins urgente — mais un modèle peut s'y appuyer au lieu de lire le motif.

Le modèle est compact. 1,7 milliard de paramètres : suffisant pour apprendre un format et une décision à trois classes, insuffisant pour un raisonnement clinique nuancé.

Risque d'usage. Le principal risque n'est pas technique mais organisationnel : qu'un outil d'aide devienne en pratique un outil de décision. La réponse expose délibérément le désaccord avec la règle, et l'interface d'accueil doit conserver une action de réévaluation systématique.

Passage en production : checklist go / no-go

#	Critère	Seuil	État
1	Catalogue clinique relu et validé par deux urgentistes	100 % des présentations	à faire — validation clinique requise
2	Jeu d'évaluation annoté indépendamment par deux soignants	accord inter-annotateurs $\geq 0,8$	à faire — annotation indépendante requise
3	Sous-triage sur le jeu clinique	borne haute de l'IC 95 % ≤ 5 %	indéterminé sur ce jeu — 27,5 % mesuré, IC 95 % jusqu'à 43,9 % sur 40 cas urgents
4	Respect du format	borne basse de l'IC 95 % ≥ 99 %	indéterminé sur ce jeu — 100 % mesuré, IC 95 % à partir de 94 % sur 60 cas
5	Latence 95 ^e centile à quatre requêtes simultanées	$\leq 2\,000$ ms	atteint (1830 ms)
6	Journal d'audit persistant et anonymisé	vérifié en conditions réelles	atteint — volume persistant et masquage vérifiés par les tests
7	Endpoint authentifié, limité en débit, derrière HTTPS	vérifié	atteint en local — HTTPS à la charge de l'hébergeur
8	Procédure de retour arrière éprouvée	testée sur l'environnement pilote	à faire — à éprouver sur l'environnement pilote
9	Analyse d'impact relative à la protection des données	validée par le DPO du CHSA	à faire — analyse d'impact à conduire avec le DPO
10	Qualification réglementaire du dispositif	statut tranché avec le service juridique	à faire — qualification à trancher avec le service juridique

Les critères 1, 2, 9 et 10 ne relèvent pas de l'ingénierie et conditionnent tout le reste. Aucun déploiement, même pilote et supervisé, ne doit être engagé avant que les critères 1, 2 et 9 soient satisfaits.

Les critères 3 et 4 se tranchent sur la **borne défavorable** de l'intervalle, et non sur le point central : sur une quarantaine de cas urgents, même zéro sous-triage laisse un intervalle qui monte à 8,8 %, au-dessus du seuil exigé.

Feuille de route

Chaque phase s'ouvre sur ce qui manque à la précédente, et la validation clinique conditionne les autres.

Phase	Durée	Contenu	Charge estimée
3a — Validation clinique	2 mois	relecture du catalogue par deux urgentistes ; annotation indépendante de 300 cas réels anonymisés ; accord inter-annotateurs	15 j d'ingénierie, 10 j de temps médical
3b — Montée en capacité	2 mois	modèle de 8 à 32 milliards de paramètres, QLoRA sur carte de 48 à 80 Go louée à l'heure	20 j, 400 à 800 € de calcul
3c — Pilote supervisé	3 mois	double lecture sur un poste d'accueil : l'agent propose, le soignant décide, chaque désaccord est consigné	25 j, un GPU dédié
3d — Industrialisation	3 mois	autoscaling, registre de modèles, réentraînement sur les cas du pilote, détection de dérive, astreinte	40 j, 500 à 900 € par mois d'hébergement

L'empreinte mesurée en phase 2 donne l'ordre de grandeur de la phase 3b : un modèle vingt fois plus gros sur un corpus quatre fois plus large reste une affaire de quelques dizaines d'heures de GPU. La phase 3c, elle, n'est pas qu'un déploiement : c'est ce qui constitue enfin un corpus issu du terrain, et reprend les critères go / no-go restés ouverts.

Conclusion

Le prototype démontre qu'un modèle compact, spécialisé sur un corpus construit pour la tâche, produit un triage **structuré, justifié et tracé**, et se déploie sur une infrastructure ordinaire.

Sur un jeu d'évaluation indépendant de 60 cas, il atteint 0,70 d'exactitude contre 0,62 pour la règle explicite qu'il doit remplacer, avec 27,5 % de sous-triage et 100 % de réponses exploitables par le système d'information.

Les fondations posées ici — vérité terrain qui ne vient pas de la règle évaluée, séparation vérifiée par le code, contrôles de sécurité lisibles, traçabilité anonymisée, déploiement automatisé — sont celles sur lesquelles une validation clinique peut s'appuyer. Elles ne la remplacent pas.

Annexe A — Reproduire le projet

```
uv sync
uv run python scripts/01_build_dataset.py          # dataset et jeu d'évaluation
uv run python scripts/02_tune_hyperparameters.py   # comparaison des configurations
uv run python scripts/03_train_sft.py              # fine-tuning supervisé
uv run python scripts/04_merge_and_export.py --adapter sft
uv run python scripts/05_train_dpo.py              # alignement par préférences
uv run python scripts/04_merge_and_export.py --adapter dpo
uv run python scripts/06_evaluate.py               # évaluation comparée aux références
docker compose -f deploy/docker-compose.yml up     # endpoint vLLM + passerelle
uv run python scripts/07_benchmark_endpoint.py --api-key "$TRIAGE_API_KEY" # latence de bout en bout
uv run python scripts/08_publish_hf.py --what tout # dataset et poids sur le Hub
uv run python scripts/09_build_report.py           # figures et ce document
uv run python scripts/10_build_slides.py           # support de soutenance
uv run python scripts/11_package_deliverable.py    # archive de livrables
```

Graine fixée à 42, hyperparamètres versionnés, exécutions d'entraînement suivies avec MLflow en local et résumées en JSON dans reports/training/.

Annexe B — Sources, licences et références

Source	Langue	Licence	Rôle dans le projet
vignette_clinique	fr + en	MIT	Vérité terrain du triage : le niveau vient de la présentation, pas du texte.
mediqa1	fr	CC BY 4.0	Corpus du cahier des charges, et le seul à décrire des patients. Socle des vignettes cliniques françaises authentiques.
medquad	en	CC BY 4.0	Corpus du cahier des charges. Descriptions de symptômes, étiquetées par la règle (confiance moyenne).
medmcqa	en	Apache-2.0	Hors cahier des charges, ajouté faute de vignettes cliniques anglophones dans les corpus imposés.
frenchmedmcqa	fr	Apache-2.0	Corpus du cahier des charges. Questions de pharmacie, dont aucune n'est étiquetable en triage.
ultramedical_preference	en	MIT	Jeu de préférences externe, tenu à l'écart de l'entraînement : mesure indépendante de l'alignement.

Deux de ces dépôts sont des miroirs qui ne déclarent pas de licence. Celles reportées ici ont été lues sur les dépôts d'origine — le LICENSE.txt de abachaa/MedQuAD est le texte CC BY 4.0, et qanastek/frenchmedmcqa déclare Apache-2.0.

Référence citée. Goh E., Gallo R., Hom J. *et al.*, « Large Language Model Influence on Diagnostic Reasoning: A Randomized Clinical Trial », *JAMA Network Open*, 2024, 7(10):e2440969. jamanetwork.com/journals/jamanetworkopen/fullarticle/2825395

Outils. PyTorch (calcul), Unsloth (noyaux de fine-tuning), Hugging Face Transformers, TRL et PEFT (entraînement et alignement), MLflow (suivi d'expériences), Presidio (anonymisation), vLLM (service d'inférence), FastAPI (passerelle), Docker et GitHub Actions (conteneurisation et automatisation). Leurs versions exactes sont figées dans uv.lock ; celles qui ont produit les chiffres de ce rapport sont en annexe C.

Annexe C — Version évaluée

Les chiffres de ce rapport viennent de la révision 52ba493 du dépôt : Qwen/Qwen3-1.7B-Base spécialisé en qwen3-1.7b-triage-dpo-merged, entraîné et évalué sur NVIDIA GeForce RTX 4060 Ti, 16 Go.

Bibliothèques relevées à l'exécution : PyTorch 2.12.1+cu130, Transformers 5.5.0, TRL 0.24.0.